

1. Introduction et question de recherche

1.1 Question étudiée :

Peut-on prédire la souscription d'un client à un dépôt à terme bancaire à partir de ses caractéristiques socio-démographiques, comportementales et macroéconomiques à l'aide de méthodes de Data Mining ?

1.2 Objectifs de l'étude

- Construire et comparer plusieurs modèles de classification
- Identifier les facteurs déterminants de la souscription
- Évaluer les performances prédictives des méthodes de Data Mining

2. Contexte et motivations de l'étude

Le secteur bancaire évolue dans un environnement caractérisé par une concurrence accrue, une pression sur les marges et une exigence croissante de rentabilité des actions commerciales. Dans ce contexte, les établissements bancaires cherchent à optimiser leurs stratégies marketing, notamment dans la commercialisation de produits d'épargne tels que les dépôts à terme. Les campagnes de démarchage de masse, historiquement utilisées, se révèlent coûteuses et peu efficaces, tout en pouvant nuire à la relation client. L'exploitation des données clients constitue dès lors un levier stratégique majeur. Les banques disposent de nombreuses informations relatives aux caractéristiques socio-démographiques des clients, à leur historique de contacts commerciaux ainsi qu'à l'environnement macroéconomique. L'analyse de ces données à l'aide de méthodes de Data Mining permet d'anticiper les comportements de souscription et de cibler plus efficacement les campagnes marketing. Être en mesure de prédire la probabilité de souscription d'un client à un dépôt à terme permet ainsi de réduire les coûts commerciaux, d'améliorer le taux de conversion et d'optimiser l'allocation des ressources. Cette problématique présente également un intérêt académique important. Elle s'inscrit dans le cadre d'un problème de classification binaire supervisée, fréquemment étudié dans la littérature en Data Mining. Elle permet de comparer différentes méthodes de classification, allant de modèles interprétables tels que la régression logistique ou les arbres de décision à des modèles plus complexes orientés performance, comme les forêts aléatoires ou les méthodes de boosting.

Par ailleurs, la présence d'un déséquilibre entre les classes et l'intégration de variables macroéconomiques soulève des enjeux méthodologiques centraux en apprentissage automatique. Ainsi, cette étude se situe à l'interface entre enjeux managériaux et questionnements méthodologiques, en montrant comment les techniques de Data Mining peuvent contribuer à une meilleure aide à la décision dans le cadre du marketing

bancaire. 3. Présentation des données utilisées Les données proviennent du jeu de données Bank Marketing mis à disposition par la plateforme UCI Machine Learning Repository via le lien suivant : [Bank Marketing - UCI Machine Learning Repository](#)

3. Présentation des données

Statistiques descriptives des variables

Variable	Min	1erQ	Mediane	Moyenne	3eQ	Max
Campaign	1.000	1.000	2.000	2568	3.000	56.000
Pdays	0.00	999.0	999.0	962.5	999.0	999.0
Previous	0.000	0.00	0.00	0.173	0.00	7.000
Emp.var.rate	-3.400	-1.800	1.100	0.08189	1.400	1.400
Cons.price.idx	92.2	93.08	93.75	93.58	93.99	94.77
Cons.cof.idx	-50.8	-42.7	-41.8	-40.5	-36.4	-26.9
Euribor.3m	0.634	1.344	4.857	3.621	4961	5.045
Nr.employed	4964	5099	5191	5167	5228	5228

Variables catégorielles

Variables	Modalité	Effectif
poutcome	Failure	4252
	Nonexistant	35563
	Success	1373
Y	No	36548
	Yes	4640

Le jeu de données utilisé dans cette étude comprend 41 188 observations et 21 variables. Chaque observation correspond à un client contacté dans le cadre d'une campagne de marketing bancaire visant la souscription à un dépôt à terme. Les données décrivent à la fois les caractéristiques individuelles des clients, les modalités des campagnes marketing et le contexte macroéconomique dans lequel ces campagnes ont été menées.

3.2 Description des variables :

Les variables peuvent être regroupées en trois grandes catégories.

a. Variables socio-démographiques :

Ces variables décrivent le profil des clients :

- L'âge (age), variable numérique allant de 17 à 98 ans, avec une moyenne d'environ 40 ans ;
- la profession (job) ;
- l'état civil (marital) ;

- le niveau d'éducation (education) ;
- l'existence d'un crédit en défaut (default) ;
- la présence d'un prêt immobilier (housing) ;
- la présence d'un prêt personnel (loan).

b. Variables liées à la campagne marketing Elles décrivent les interactions entre la banque et les clients :



- le type de contact (contact) ;
- le mois (month) et le jour de la semaine (day_of_week) du dernier contact ;
- la durée du dernier appel (duration), exprimée en secondes ;
- le nombre de contacts effectués durant la campagne (campaign) ;
- le nombre de jours écoulés depuis le dernier contact lors d'une campagne précédente (pdays) ;
- le nombre de contacts réalisés avant la campagne en cours (previous) ;
- le résultat de la campagne précédente (poutcome).

c. Variables macroéconomiques Ces variables décrivent l'environnement économique global :


- Le taux de variation de l'emploi (emp.var.rate) ;
- l'indice des prix à la consommation (cons.price.idx) ;
- l'indice de confiance des consommateurs (cons.conf.idx) ;
- le taux interbancaire à trois mois (euribor3m) ;
- le nombre de salariés (nr.employed).

La variable cible y est binaire et indique si le client a souscrit (yes) ou non (no) à un dépôt à terme à l'issue de la campagne.

3.3 Analyse exploratoire



Le graphique montre une répartition très déséquilibrée de la variable cible : la grande majorité des clients n'a pas souscrit au dépôt à terme, tandis que seuls quelques-uns ont effectivement souscrit. Ce déséquilibre est typique des campagnes de marketing direct, où le taux de conversion est faible. D'un point de vue méthodologique, cela signifie qu'un modèle peut obtenir une bonne accuracy simplement en prédisant systématiquement « no », sans réellement détecter les souscripteurs, ce qui impose d'utiliser des indicateurs adaptés et des méthodes capables de traiter le déséquilibre des classes



Le boxplot de la durée du dernier appel met en évidence une différence nette entre les deux groupes. Les clients ayant souscrit présentent des durées d'appel nettement plus élevées que ceux n'ayant pas souscrit, tant en termes de médiane que de dispersion. Cette observation suggère une forte association entre la durée du contact et la probabilité de souscription. Néanmoins, cette relation doit être interprétée avec prudence, car la durée de l'appel est observée après l'interaction commerciale et peut introduire une fuite d'information dans un cadre de prédiction ex ante. Le graphique relatif au résultat de la campagne précédente montre un contraste particulièrement marqué. Les clients ayant connu un succès lors d'une campagne antérieure présentent une probabilité de souscription très élevée lors de la campagne étudiée. À l'inverse, les clients pour lesquels la campagne précédente s'est soldée par un échec ou pour lesquels aucune campagne antérieure n'a eu lieu affichent des taux de souscription nettement plus faibles. Ce résultat met en évidence le fort pouvoir prédictif de la variable poutcome. L'analyse bivariable montre que deux variables discriminent clairement les souscripteurs des non-souscripteurs : la durée de l'appel, nettement plus élevée chez les clients qui souscrivent, et le résultat de la campagne précédente, avec un taux de conversion très fort chez ceux ayant déjà répondu positivement. Ces deux facteurs révèlent des comportements distincts et confirment que la décision de souscription dépend à la fois de la qualité de l'interaction commerciale et de l'historique du client.

La matrice de corrélation montre que plusieurs variables macroéconomiques sont très fortement corrélées entre elles, ce qui indique une forte redondance d'information et un

risque de multicolinéarité, particulièrement problématique pour des modèles linéaires comme la régression logistique. La seule corrélation notable avec la variable cible concerne la durée de l'appel, qui est modérément associée à la souscription, mais doit être utilisée avec prudence en raison d'un risque de fuite d'information. Les autres variables numériques présentent des corrélations faibles avec la cible, ce qui confirme que la souscription résulte d'une combinaison de facteurs plutôt que d'un seul indicateur isolé. Ces constats renforcent la nécessité d'un prétraitement rigoureux et de méthodes de Data Mining capables de capturer des relations complexes.

4. Modélisation et résultats

Deux méthodes de classification supervisée sont mobilisées :

- la régression logistique, en tant que modèle de référence interprétable, adapté à une variable cible binaire et permettant d'identifier les déterminants de la souscription ;
- la forêt aléatoire (Random Forest), en tant que méthode non paramétrique, robuste aux relations non linéaires, aux interactions complexes et au grand nombre de variables, particulièrement adaptée à un contexte de données hétérogènes et de classes déséquilibrées.

4.1 Modèle de Regression logistique

- **Âge (age)** : le coefficient est positif et significatif. Cela indique que, toutes choses égales par ailleurs, la probabilité de souscription augmente légèrement avec l'âge. Cet effet est statistiquement significatif mais de faible ampleur, suggérant un rôle modéré de l'âge dans la décision de souscription.
- **État civil** (marital) et niveau d'éducation (education) présentent également des coefficients positifs et significatifs. Ces résultats suggèrent que la situation familiale et le capital éducatif influencent la propension à souscrire à un dépôt à terme.
- En revanche, la **profession (job)** n'apparaît pas statistiquement significative une fois les autres variables contrôlées, ce qui suggère que son effet est capturé par d'autres dimensions du modèle.
- Le fait d'être en **défaut de paiement (default)** a un effet négatif et fortement significatif sur la probabilité de souscription. Les clients en situation de défaut sont donc nettement moins enclins à souscrire à un dépôt à terme.
- La présence d'un **prêt immobilier (housing)** ou d'un prêt personnel (loan) ne présente pas d'effet significatif dans ce modèle, une fois les autres variables prises en compte.
- Le type de **contact (contact)** et le **mois du contact (month)** ont des effets négatifs et fortement significatifs, indiquant que certaines modalités de contact et périodes de l'année sont associées à une probabilité plus faible de souscription.

- La **durée du dernier appel (duration)** présente un coefficient positif très élevé et extrêmement significatif. Cela confirme que des appels plus longs sont fortement associés à une probabilité accrue de souscription. Toutefois, ce résultat doit être interprété avec prudence, car cette variable est observée après l'interaction commerciale et peut introduire une fuite d'information dans un cadre strictement prédictif.
- Le nombre de contacts durant la campagne (**campaign**) et le nombre de jours écoulés depuis le dernier contact (**pdays**) ont des effets négatifs et significatifs, suggérant qu'une pression commerciale excessive ou des contacts trop espacés réduisent la probabilité de succès.
- Le résultat de la campagne précédente (**poutcome**) a un effet positif et significatif, confirmant que les clients ayant déjà répondu favorablement à une campagne passée sont plus susceptibles de souscrire à nouveau.
- Le taux de variation de l'emploi (**emp.var.rate**) et le nombre de salariés (**nr.employed**) ont des effets négatifs et fortement significatifs, suggérant que certaines phases du cycle économique sont moins favorables à la souscription.
- À l'inverse, le taux interbancaire à trois mois (**euribor3m**) et l'indice des prix à la consommation (**cons.price.idx**) ont des effets positifs et significatifs, indiquant que les conditions monétaires et inflationnistes influencent les comportements d'épargne.
- L'indice de confiance des consommateurs (**cons.conf.idx**) n'apparaît pas significatif une fois les autres variables contrôlées.

La déviance nulle du modèle est de 14 187, tandis que la déviance résiduelle s'élève à 8 558, ce qui indique une réduction substantielle de l'erreur une fois les variables explicatives introduites.

Prédiction sur le jeu de test

La matrice de confusion met en évidence une forte capacité du modèle à identifier correctement la classe majoritaire, définie ici comme la classe positive ("no") ; 17 759 clients n'ayant pas souscrit sont correctement classés, 440 clients n'ayant pas souscrit sont incorrectement classés comme souscripteurs, 944 clients ayant souscrit sont correctement identifiés et 1 451 clients ayant souscrit sont incorrectement classés comme non-souscripteurs.


Ces résultats montrent que le modèle privilégie la prédiction de la classe "no", ce qui conduit à un nombre relativement élevé de faux négatifs pour la classe "yes". La sensibilité, égale à 97,58 %, indique que le modèle identifie correctement la quasi-totalité des clients n'ayant pas souscrit. Cette performance très élevée traduit une excellente capacité à reconnaître la classe majoritaire. En revanche, la spécificité est plus faible, à 39,42 %, ce qui signifie que le modèle éprouve des difficultés à détecter

correctement les clients ayant effectivement souscrit. Autrement dit, une part importante des souscripteurs est classée à tort comme non-souscripteurs. La précision positive (Positive Predictive Value) est élevée (92,45 %), indiquant que lorsqu'un client est prédit comme non-souscripteur, cette prédiction est généralement correcte. À l'inverse, la valeur prédictive négative est plus modérée (68,21 %), traduisant une incertitude plus importante lorsque le modèle prédit une souscription. Le coefficient de Kappa, égal à 0,45, indique un accord modéré entre les prédictions du modèle et les observations réelles, au-delà de ce qui serait attendu par le hasard. La balanced accuracy, de 68,50 %, confirme que les performances du modèle sont déséquilibrées entre les deux classes. La régression logistique présente une bonne performance globale, avec une accuracy de 90,82 %, mais cette performance repose principalement sur une très bonne détection des non-souscripteurs. La capacité du modèle à identifier les clients souscripteurs reste limitée, ce qui met en évidence les effets du déséquilibre des classes et justifie le recours à des modèles plus flexibles, tels que les forêts aléatoires, pour améliorer la détection de la classe d'intérêt.

Courbe ROC et AUC – Régression logistique

Dans le graphique présenté, la courbe ROC se situe nettement au-dessus de la diagonale correspondant à une classification aléatoire et adopte une forme concave, proche du coin supérieur gauche. Cette configuration indique que le modèle est capable d'atteindre des niveaux élevés de sensibilité pour des taux relativement faibles de faux positifs, traduisant une bonne capacité de discrimination.

L'aire sous la courbe (AUC) est égale à 0,9265, ce qui correspond à une excellente performance discriminante. Concrètement, cette valeur signifie qu'il existe une probabilité d'environ 92,65 % pour que le modèle attribue une probabilité de souscription plus élevée à un client ayant effectivement souscrit qu'à un client n'ayant pas souscrit. Cette performance est nettement supérieure à celle d'un modèle aléatoire



(AUC = 0,5) et confirme la pertinence de la régression logistique pour ce problème de classification. Ces résultats complètent l'analyse fondée sur la matrice de confusion et l'accuracy. Bien que la régression logistique présente une capacité limitée à détecter la classe minoritaire au seuil de classification retenu, la valeur élevée de l'AUC montre que le modèle classe correctement les individus en termes de probabilité de souscription. Cela suggère qu'un ajustement du seuil de décision


pourrait améliorer la détection des souscripteurs sans dégrader excessivement la performance globale.

4.2 Modèle Random Forest

Le modèle de forêt aléatoire a été entraîné sur l'échantillon d'apprentissage à l'aide de 100 arbres de décision. À chaque division d'un nœud, quatre variables ont été testées aléatoirement, conformément au principe du Random Forest visant à réduire la variance et à améliorer la capacité de généralisation du modèle. L'erreur estimée out-of-bag (OOB) du modèle est de 8,56 %, ce qui correspond à une précision globale d'environ 91,14 %. Cette performance indique que le modèle parvient globalement à bien discriminer les clients souscripteurs et non souscripteurs, sans avoir recours à un jeu de validation externe pour cette estimation. NB : Un découpage équilibré des données a été retenu afin de disposer d'un échantillon de test suffisamment large pour évaluer de manière robuste les performances du modèle.

Prédictions sur le jeu de test, évaluation des performances et matrice de confusion

Le modèle de forêt aléatoire présente une performance globale élevée, avec une accuracy de 91,14 %, ce qui signifie que plus de neuf observations sur dix sont correctement classées sur le jeu de test. Cette performance est statistiquement significative et nettement supérieure au *No Information Rate* de 88,37 %, confirmant que le modèle apporte une réelle valeur prédictive par rapport à une stratégie naïve consistant à prédire systématiquement la classe majoritaire. L'analyse de la matrice de confusion montre que 17 587 observations de la classe 1 sont correctement prédites, contre 612 erreurs, tandis que 1 212 observations de la classe 2 sont correctement




identifiées, mais 1 212 sont mal classées. Ces résultats se traduisent par une sensibilité très élevée de 96,64 %, indiquant que le modèle détecte presque tous les individus appartenant à la classe positive, mais par une spécificité plus limitée de 49,39 %, révélant des difficultés à reconnaître correctement la classe minoritaire.

La valeur prédictive positive, élevée à 93,55 %, montre que les prédictions de la classe 1 sont fiables, tandis que la valeur prédictive négative, plus modérée (65,91 %), reflète une incertitude plus importante dans les prédictions de la classe 2. Le coefficient de Kappa de 0,52 indique un accord modéré à substantiel entre les prédictions et les classes réelles, au-delà du hasard, et la balanced accuracy de 73,02 % confirme que, malgré une excellente performance globale, les résultats du modèle restent déséquilibrés entre les deux classes. Dans l'ensemble, le modèle se distingue par une

très forte capacité à identifier la classe majoritaire, mais sa performance sur la classe minoritaire demeure perfectible, ce qui est cohérent avec le déséquilibre structurel des données.

Le graphique de la matrice de confusion illustre visuellement ces résultats. La concentration élevée d'observations dans la cellule correspondant aux vraies prédictions de la classe 1 confirme la domination de cette classe et la bonne performance globale du modèle. En revanche, la coloration plus homogène des cellules associées à la classe 2 souligne la difficulté du modèle à discriminer correctement cette classe. Le modèle de forêt aléatoire présente une excellente performance globale, avec une accuracy de 91,16 %, mais montre une asymétrie marquée dans ses performances selon les classes. Il se distingue par une très forte capacité à détecter la classe positive, au prix d'une spécificité plus faible pour la classe négative. Ces résultats soulignent l'impact du déséquilibre des classes et justifient l'exploration d'ajustements méthodologiques afin d'améliorer l'équilibre des performances, notamment en ce qui concerne la détection de la classe minoritaire.

Courbe ROC et AUC



Dans ce graphique, on voit que la courbe ROC se situe nettement au-dessus de la diagonale représentant une classification aléatoire. Elle est fortement concave et proche du coin supérieur gauche, ce qui traduit une excellente capacité de discrimination du modèle. Pour de faibles niveaux de faux positifs, le modèle parvient déjà à atteindre des niveaux élevés de sensibilité, indiquant qu'il identifie efficacement les clients susceptibles de souscrire. L'aire sous la courbe (AUC) est égale à 0,942, ce qui correspond à une

performance très élevée. Concrètement, cette valeur signifie qu'il existe une probabilité de 94,2 % pour que le modèle attribue un score de probabilité plus élevé à un client ayant effectivement souscrit qu'à un client n'ayant pas souscrit. Une telle valeur confirme que le modèle distingue très efficacement les deux classes, indépendamment du seuil de classification retenu.

5. Comparaison des modèles

Critère	Regression logistique	Random Forest
Interprétation	Excellente	Faible
Prédiction globale	Très bonne	Excellente
Détection classe minoritaire	Faible	Meilleure
Sensibilité au déséquilibre	Forte	Faible
Sensibilité à la colinéarité	Forte	Faible
AUC	0.926	0.942

Conclusion : Random Forest est le meilleur modèle pour la prédiction, tandis que la logit reste utile pour l'analyse des déterminants.

6. Discussion et limites des modèles

Les résultats montrent que la prédiction de souscription est possible avec un niveau de performance élevé. Les variables les plus déterminantes proviennent des interactions commerciales (duration, poutcome) plus que des caractéristiques individuelles.

Limites identifiées :

Déséquilibre important entre classes ; Multi colinéarité dans les variables macroéconomiques ; La variable duration risque de fausser l'évaluation car observée après l'appel ; Encodage factoriel simplifié pouvant perdre de l'information.

Améliorations possibles : Oversampling ou SMOTE pour équilibrer les classes ; Exclure ou neutraliser la variable duration pour une prédiction ex-ante réelle ; Ajuster le seuil de décision pour optimiser la détection des souscripteurs ; Tester d'autres modèles (XGBoost, Gradient Boosting, SVM).

7. Conclusion générale

Cette étude montre qu'il est possible de prédire la souscription à un dépôt à terme en combinant des méthodes de Data Mining et une analyse approfondie des variables comportementales et macroéconomiques.

Le Random Forest se distingue par sa performance et sa robustesse, tandis que la régression logistique permet de comprendre précisément les déterminants de la souscription.

Au-delà des résultats prédictifs, le travail met en évidence l'importance de : maîtriser le déséquilibre des classes, traiter la multicollinéarité, évaluer correctement les variables potentiellement post-dictives.

Les modèles développés peuvent améliorer le ciblage marketing bancaire en réduisant les coûts tout en augmentant la conversion.

Bibliographie

- **UCI Machine Learning Repository.** (2025). *Bank Marketing Dataset*. Retrieved from <https://archive.ics.uci.edu/ml/datasets/Bank+Marketing>
- **Moro, S., Cortez, P., & Rita, P.** (2014). *A data-driven approach to predict the success of bank telemarketing*. *Decision Support Systems*, 62, 22–31.
- **Breiman, L.** (2001). *Random Forests*. *Machine Learning*, 45(1), 5–32.
- **Han, J., Kamber, M., & Pei, J.** (2012). *Data Mining: Concepts and Techniques*. Morgan Kaufmann.
- **Witten, I. H., Frank, E., Hall, M. A., & Pal, C. J.** (2016). *Data Mining: Practical Machine Learning Tools and Techniques* (4th ed.). Morgan Kaufmann.
- **Hosmer, D. W., Lemeshow, S., & Sturdivant, R. X.** (2013). *Applied Logistic Regression* (3rd ed.). Wiley.
- **Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P.** (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. *Journal of Artificial Intelligence Research*, 16, 321–357.
- **He, H., & Garcia, E. A.** (2009). *Learning from imbalanced data*. *IEEE Transactions on Knowledge and Data Engineering*, 21(9), 1263–1284.
- **Kumar, V., & Reinartz, W.** (2018). *Customer Relationship Management: Concept, Strategy, and Tools*. Springer.
- **Verbeke, W., Dejaeger, K., Martens, D., Hur, J., & Baesens, B.** (2012). *New insights into churn prediction in the telecommunication sector: A profit-driven data mining approach*. *European Journal of Operational Research*, 218(1), 211–229.